

# Как Skyeng сократил 30% техдепартамента через внедрение ИИ

TL;DR. Ирина Шанина, СТО Skyeng, рассказывает, как за 2024–2026 годы компания выровняла процессы и метрики, раскатала AI-first подход, создала внутреннего виртуального сотрудника «Джулия» и в итоге сократила ~30% техперсонала, при этом сократив lead time на 35% и нарастив объём работы. Ключевые тезисы жёсткие: балласт (сопротивляющиеся ИИ) не нужен, джунов в компании нет, использование ИИ обязательно для сеньоров, а облачные модели предпочтительнее локальных из-за скорости развития.

## Хронология внедрения ИИ в Skyeng

- Конец 2024: выравнивание процессов и метрик по всем командам — единый workflow, сопоставимые метрики, дашборд производительности каждой команды и сотрудника.
- Начало 2025: установка SEO «AI First» — раскатка ИИ во всех департаментах (продукт, разработка, операционка, legal). Первые шаги — воркшопы и мастер-классы от энтузиастов внутри компании.
- 2025: компания централизованно закупает доступ к Cursor, Claude Code и др., берёт на себя менеджмент учёток, чтобы убрать поводы для сопротивления.
- 2025: Ирина становится СТО, вводит прозрачную систему грейдирования и обязательное использование ИИ для сеньоров (разработка, QA, системный анализ).
- Осень 2025: создан виртуальный сотрудник «Джулия» для рутинных задач (по мотивам хайпа вокруг OpenClaw).
- Начало 2026: по финансовым причинам нужно сократить треть штата — ИИ раскручивают «на полную катушку», снимают лимиты на токены для части сотрудников.

## Что такое «Джулия» и как она устроена

- Внутренний виртуальный сотрудник во внутренних системах компании; задачу ставят через Jira, есть доступы к GitLab и Confluence.
- Под капотом: отдельная машина/сервер с установленным Cursor; на вход принимает пререквизиты (что за задача, залинкованные сервисы, часть кодовой базы).
- Доступ практически ко всем системам компании, КРОМЕ связанных с персональными данными; связка с Jira и внутренним мессенджером через триггеры.
- Задачи: рутинные массовые изменения (обновление библиотек, рефакторинг, чистка легаси), технические ресёрчи (в т.ч. для продактов и других отделов), всё код-ревью, автотесты UI/фронтенда через Playwright.
- Делает merge request и код-ревью, но сам деплой остаётся ответственностью живого разработчика.
- Код-ревью занимает максимум ~10 минут с несколькими итерациями вместо часов ожидания.

## Результаты и экономика<sup>1</sup>

| Показатель | Значение / деталь |
|------------|-------------------|
|------------|-------------------|

|                         |             |
|-------------------------|-------------|
| Сокращение техперсонала | ~30% за год |
|-------------------------|-------------|

|                     |                                    |
|---------------------|------------------------------------|
| Изменение lead time | –35% (быстрее), с июня 2025 к 2026 |
|---------------------|------------------------------------|

|                                               |                                       |
|-----------------------------------------------|---------------------------------------|
| Рост производительности отдельных сотрудников | х3 у топов, х2 у части, +50% у других |
|-----------------------------------------------|---------------------------------------|

|                               |                                     |
|-------------------------------|-------------------------------------|
| Стоимость код-ревью на старте | ~\$500 за один день (мощная модель) |
|-------------------------------|-------------------------------------|

|                                                |                       |
|------------------------------------------------|-----------------------|
| Стоимость код-ревью после перехода на Composer | практически бесплатно |
|------------------------------------------------|-----------------------|

|                  |                                                                |
|------------------|----------------------------------------------------------------|
| Лимиты на токены | сняты для части сотрудников — дало «сумасшедший» буст скорости |
|------------------|----------------------------------------------------------------|

|                                                  |                                                 |
|--------------------------------------------------|-------------------------------------------------|
| Инцидент с адаптацией тестов (по опыту Котелова) | ~1500 кривых тестов за месяц, писал Claude Opus |
|--------------------------------------------------|-------------------------------------------------|

## Кого увольнять и кого нанимать (критерии от Ирины)

- Оставлять: самых энергичных и производительных; в приоритете — максимально компетентных в критичном домене.
- Убирать в первую очередь: тех, кто не готов к ИИ, «сопротивляшек», уставших, выгоревших и тяжело принимающих изменения — «балласт».
- При найме: спрашивать, как человек уже работает с ИИ, и смотреть на реакцию (доверие/недоверие).
- На собеседовании: дать задачу решить с помощью ИИ и посмотреть, КАК человек формулирует запрос.
- Топ-маркер: кандидат работает с агентом голосом (изменённая речь), а не набирает запрос руками на клавиатуре.
- Возраст значения не имеет (эйджизма нет) — важна готовность перестраивать mindset; это черта характера / софт-скиллы.

## Инфраструктура и принципы доступа ИИ к данным

- Главный минимум безопасности — изоляция персональных данных (ПДН); это вопрос правильной инфраструктуры компании, которую надо было выстроить ещё пару лет назад.
- Агент не имеет доступа к прод, продовым базам и ПДН — только к репликам и логам.
- Рекомендация: максимальный доступ, но по большей части только на чтение; запись = потеря контроля.
- Разделение по итерациям: у проверяющего агента нет доступа к изменению кода, у изменяющего — есть. Одна цель — одна итерация.
- Защита от инцидентов: канареечный деплой и другие давно существующие механизмы позволяют быстро откатывать.
- Построили MCP Gateway: одним запросом с ссылкой на лог инженер/QA/техподдержка получают понятный отчёт о поломке.

## Модели: облако против локального контура

- Skyeng выбрал облачные решения: развиваются быстро, профит доступен сразу, не нужно содержать людей и ресурсы под инфраструктуру.
- Экономический расчёт локального решения делали давно — было невыгодно и «неинтересно» (медленнее развивается).
- Не гнаться за самой дорогой моделью — смысла нет; для код-ревью отлично подошёл дешёвый Cursor Composer (по сути Kimi ~2.6).
- Ведущий отмечает: крупным корпорациям / госсектору Cursor недоступен — им подойдёт селф-хост той же модели (Kimi) в закрытом контуре для повторения кейса.
- Передовые модели работают медленно (35–60 токенов/с, ресёрч может занимать 25+ минут) — решается параллелизацией: разработчик даёт задачу агенту и переключается на другую.

## Взгляд в будущее индустрии

- Джунов в компании нет уже давно — «нафига они нужны, если есть Джулия».
- Прогноз ведущего: через 5 лет не будет мидлов, через 10 — сеньоров; проблема кадрового резерва Ирину «беспокоит», но объём рабочих рук в будущем потребует меньший.
- Ожидаемая сегрегация ИТ: большая каста вайб-кодеров (верхний уровень, без глубокого погружения) и узкая «суперэлита» настоящих инженеров для действительно сложных задач.
- Вайб-кодинг в крупной компании — да, для быстрых MVP и проверки гипотез; но не в критичных местах вроде биллинга банка.
- Легаси без документации: дело не в модели, а в нехватке пререквизитов и бизнес-контекста; часто достаточно дописать документацию ИИ, иногда — переписать с нуля (с ИИ это дешевле).
- Главные навыки сейчас: умение пользоваться ИИ и готовность перестраиваться; остальное «можно подтянуть». Не использовать ИИ уже сейчас — «стрёмно».

## Открытые вопросы

- Как именно устроена «Джулия» технически (Ирина предложила отдельный тех-толк, деталей в видео нет).
- Насколько «честны» 35% сокращения lead time с учётом того, что оставшиеся сотрудники могли работать эффективнее из-за страха увольнения — изолировать вклад именно ИИ в интервью не удалось.
- Как в реальности решается проблема кадрового резерва (отсутствие джунов и мидлов) на горизонте 5–10 лет — конкретного ответа нет.
- Полная сумма экономии от снятия лимитов на токены против затрат — приводятся только качественные оценки.
- Как компания борется с «токен-максингом» помимо анализа соотношения потребления к закрытым задачам/деплойам.
- Детали расчёта, при котором локальные модели оказались невыгодны, не раскрыты.

## Моё мнение

Кейс интересен именно операционной дисциплиной: сначала (2024) выстроили прозрачные метрики, и только потом внедряли ИИ — без этой базы любые заявления об «эффективности» были бы неverified. Однако я лишь частично согласен с выводами. Во-первых, сам ведущий поднял ключевую методологическую дыру: невозможно изолировать вклад ИИ от эффекта страха и от того, что в «жирные годы» многие компании просто перенабрали людей — комментаторы @alekseybord5373 и @AlanKhoziev справедливо замечают, что сокращение трети штата легко выдать за «эффективность топ-менеджера», хотя это может быть обычная оптимизация раздутого штата. Во-вторых, риторика про «балласт» и «естественный отбор» для джунов без денег — это, на мой взгляд, недальновидно: как отмечает @VanuchVan, разговоры о полной замене людей звучат десятилетиями и обычно упираются в реальность; вырезав нижние грейды, компания сама уничтожает свой кадровый резерв, и Ирина это фактически признаёт, но отрицается. Что я бы сделал иначе: (1) обязательно вводил бы модель-надзиратель за регрессиями — кейс Котелова с 1500 адаптированными тестами от Opus показывает, что автономный ИИ «ленится» и его нельзя оставлять без второго контура проверки; (2) сохранял бы небольшую программу джунов как инвестицию в будущих сеньоров, а не полагался, что вайб-кодеры «дорастут» сами; (3) к метрике «–35% lead time» относился бы осторожнее и публиковал бы её вместе с контрольными факторами. Практичные же находки — обязательное использование ИИ в грейдах сеньора, оценка кандидата по тому, КАК он формулирует запрос (а не набирает ли руками), и разделение агентов «читатель/писатель» по итерациям — действительно ценны и переносимы на другие компании.

<sup>1</sup>Lead time — среднее время от взятия задачи в работу до поставки на прод. Метрики «честные», сняты с системы по оставшимся сотрудникам.