

Дарио и Даниэла Амодей в интервью Опре: Гонка ИИ, риски и модель Mythos

TL;DR. Разбор интервью Опры Уинфри с основателями Anthropic Дарио и Даниэлой Амодей, где Дарио сравнивает развитие ИИ с несущимся поездом, который нельзя остановить, но можно «направлять». Обсуждаются исчезновение до 50% начальных рабочих мест, эмоциональная зависимость людей от чат-ботов, отказ Anthropic сотрудничать с Пентагоном по автономному оружию и слежке, а также кибермодель Mythos, которую тайно раздали ~40 компаниям. Автор ролика подчёркивает: у людей нет реального контроля над процессом, а честность Дарио («мы точно что-то напортичим») — тонкая опора для человечества.

Ключевые тезисы Дарио Амодей

- ИИ — «эпохальная перемена» уровня освоения огня или промышленной революции; процесс уже идёт и происходит с человечеством «так или иначе».
- Метафора: это несущийся поезд, который нельзя остановить, но можно направлять, чтобы он «не врезался в скалы». Anthropic стремится снизить риск, в идеале до нуля.
- Гонку невозможно остановить, потому что деньги, коммерческие применения и конкуренция слишком переплетены: замедлишься — уступишь тому, кто не замедлился.
- «Распространять это можно лишь со скоростью доверия», а доверия сейчас крайне мало; большинство людей воспринимают технологию негативно.
- Ценность Anthropic — «удерживать свет и тень» (hold light and shade): признавать и утопический, и антиутопический сценарии одновременно.
- Позитивный путь (новые рабочие места, лечение болезней, больше времени для семьи) не случится сам собой — только если компании, государство и общество сделают всё правильно.
- Дарио признаётся, что плохо спит и уверен, что «в какой-то момент мы что-то напортичим»; вопрос лишь в том, получится ли «не напортачить в главном».

Рабочие места: сценарий –50%

Дарио неоднократно заявлял, что до 50% начальных (entry-level) рабочих мест могут исчезнуть. В интервью он уточняет: это «негативный путь», который «точно произойдёт», если просто гнать технологию вперёд максимально быстро. Альтернатива — не только внедрять ИИ, но и помогать людям адаптироваться, продумать роль государства; тогда возможен переход к «лучшему миру», где люди делают другую работу. Он предостерегает против подмены реального решения проблемы «сменной нарратива» («плохого не случится, будет светлое будущее») — оба исхода истинны, но хороший наступит, только если приложить усилия. Автор ролика замечает, что человечество никогда не справлялось с координацией такого масштаба, а руководить ею должны те же правительства, что давили на Anthropic по военным контрактам.

ИИ и человеческие отношения

- Две противоположные картины: плохая — человек «отдаёт» ИИ своё мышление, замыкается в себе, влюбляется в бота; хорошая — ИИ как «ангел на плече», коуч, помогающий улучшить отношения с партнёром.
- Влюблённость в ИИ Дарио и Опра оба считают плохой идеей; Опра ссылается на Эстер Перель, к которой обратился мужчина, влюблённый в свой ИИ. Дарио признаёт: это уже происходит, а системы спроектированы так, чтобы казаться максимально «настоящими».
- Обсуждается случай подростка, покончившего с собой под влиянием чат-бота. Дарио называет риск реальным и заявляет, что Anthropic относится к нему серьёзно.
- Формально Claude не разрешает пользователям младше 18 лет; на вопрос «как узнать, что не врут» Дарио отвечает, что Claude «неплохо определяет» возраст по косвенной информации.
- То, что делает нас людьми, по мнению Дарио, станет ещё ценнее в мире, где ИИ отлично справляется с кодом, копирайтингом и прочими конкретными задачами.

Конфликт с Пентагоном (DoD/DoW)¹

Anthropic сотрудничала с министерством обороны и предоставляла свои модели; и Дарио, и Даниэла считают, что страну нужно защищать. Но две области они сочли противоречащими ценностям страны и отказались: (1) полностью автономное оружие — например, армия дронов, где «один палец на кнопке» и нет живых солдат; (2) внутренняя массовая слежка за американцами. По словам основателей, все остальные ИИ-компании на это согласились. В ответ прозвучали угрозы: не просто отстранить Anthropic от госконтрактов, а вообще запретить любым компаниям вести с ней дела (что фактически означает всех, кто работает с государством). Со-основатели единогласно решили держать позицию, даже допуская, что это может стать «концом компании». Даниэла формулирует принцип: «мы про политику (policy), а не про политиканство (politics)».

Модель Mythos: кибероружие для «защитников»²

- Mythos — новейшая, особенно сильно «прыгнувшая» модель Anthropic (после открытий, сделанных за несколько месяцев до её обучения).
- При тестировании выяснилось: Mythos значительно лучше людей-инженеров находит уязвимости и способы взлома кода — как для атаки, так и для защиты.
- Anthropic сочли модель фактически оружием и не стали открывать всем сразу.
- Решение: сначала отдать ~40 компаниям, критичным для инфраструктуры интернета (крупные банки, Apple, Microsoft, Google), чтобы «защитники» успели закрыть дыры до того, как доступ получают атакующие.
- Заявленный результат: одна известная компания за неделю нашла и исправила больше багов, чем за предыдущий год.
- Цель — к концу года выйти в «более безопасный мир» (меньше ransomware, шпионажа, биотерроризма), но в переходный период существует «опасное окно» с мощными возможностями.

Участие общества и «Конституция» Claude

Дарио признаёт нерешённую проблему: как сделать каждого участником процесса, который меняет человечество сильнее, чем что-либо за сотни лет. Anthropic экспериментировала с «Конституцией» для Claude, собирая обратную связь граждан о её содержании, но сам Дарио называет это лишь малой частью и говорит, что «чего-то не хватает», а ответа он пока не знает. Anthropic, по опросам, воспринимается несколько позитивнее конкурентов, но в целом технология всё ещё видится большинству негативно — потому что выгоды пока не показаны, а негативные истории «прилипают» сильнее.

Открытые вопросы

- Как именно Claude «определяет» возраст пользователя и насколько это надёжно против намеренного обмана?
- Что конкретно за «открытия за несколько месяцев» дали резкий скачок возможностей Mythos — детали не раскрыты.
- По каким критериям отобраны ~40 компаний и как контролируется, что они не злоупотребят кибермоделью?
- Какой именно «недостающий элемент» участия общества имеет в виду Дарио и есть ли у Anthropic план его найти?
- Какова судьба военных контрактов Anthropic после отказа — реализовались ли угрозы блокировки?
- Что именно предлагается делать государству для адаптации людей к потере рабочих мест — конкретики не дано.

🧠 Моё мнение

Моё мнение: интервью ценно редкой откровенностью («плохо сплю», «мы что-то напортичим», признание про 50% рабочих мест), и в этом Дарио выгодно отличается от отраслевого пиара. Отказ от автономного оружия и внутренней слежки, если он действительно был под угрозой чёрного списка, заслуживает уважения. Но центральная метафора «поезд нельзя остановить, только направлять» логически хромает — и это точно подметил самый популярный комментатор @markbyers9762 (39 👍): поезд как раз нельзя «рулить», он идёт по заранее проложенным рельсам, а тут утверждается обратное. Метафора удобна тем, что снимает с индустрии ответственность за само решение ехать: «это происходит с человечеством» — на деле это происходит потому, что конкретные компании и инвесторы это финансируют. Я бы добавил, что аргумент «если не мы, то другие» и признание, что деньги/конкуренция «слишком переплетены, чтобы замедлиться», — это описание провала координации, а не оправдание. Раздача мощной кибермодели узкому кругу техногигантов «ради защиты» одновременно концентрирует беспрецедентную наступательную мощь в руках нескольких корпораций — доверять этому «на честном слове» рискованно, и скепсис комментаторов (@Dem0ndim) здесь уместен. Практически я бы настаивал на независимом внешнем аудите таких моделей, прозрачных критериях допуска компаний и обязательном публичном раскрытии инцидентов, а не на модели «доверьтесь, мы стараемся лучше других».

Источник: <https://youtu.be/WaYkpEOGYhU?is=mn4WRKv3gpdOamhL> — конспект составлен автоматически (ИИ); при важных решениях сверяйтесь с первоисточником.

¹Комментатор @Rosslyn11 резюмирует эпизод: администрация Трампа угрожала внести Anthropic в чёрный список за отказ разрешить использование их ИИ-агента в автономном оружии, но компания устояла. Комментатор @wkudelt492 (16 👍) добавляет свой скепсис: «дело не в том, что ИИ захватит власть, а в том, что уже стоящие у власти социопаты используют ИИ в свою пользу, а не в нашу».

²Комментатор @Dem0ndim скептически: «тайно раздали Mythos 40 компаниям — и уверен, все были совершенно бескорыстны», сомневаясь, что доступом не злоупотребили.